

Examen Final

Este examen tiene como objetivo evaluar tus habilidades prácticas en la creación y organización de un proyecto, la ejecución de herramientas bioinformáticas como BLAST, y el análisis de resultados. Asegúrate de seguir las instrucciones paso a paso, utilizando comandos correctos y estructurados, y respeta los nombres y rutas especificados.

Organización del proyecto. [20%]

Sigue las instrucciones que se te indican para generar el repositorio de trabajo (recuerda poner en un bloque de código las instrucciones a ejecutar).

Algoritmo:

- Ir al directorio `intro-bioinfo` de tu usuario.
- Genera una carpeta llamada `scripts` o `bin`
- Dentro de la carpeta `bin` o `scripts` , crea un script llamado `mk-project.sh` .
Este archivo debe tener las siguientes instrucciones/comandos a. Indicar la ruta actual de trabajo b. Crear un proyecto llamado `examen-final`
c. Crear todas las carpetas de un proyecto `bin data results doc` d. Imprimir en pantalla "estructura de proyecto creado!"
- Cambia permisos
- Ejecuta el script.

Código/Comandos

Sobre blast. [20%]

En esta sección vas a ejecutar un `blast` usando como secuencia `query` la hemoglobina beta humana.

La beta globina humana es una proteína fundamental que forma parte de la hemoglobina, una molécula esencial para el transporte de oxígeno en los vertebrados, incluida nuestra especie.

Gen asociado: La beta globina está codificada por el gen HBB (ubicado en el cromosoma 11 en humanos).

Proteína: La beta globina es una cadena polipeptídica compuesta por 147 aminoácidos. Es una subunidad de la hemoglobina, que es un tetramero formado por dos cadenas de alfa globina y dos cadenas de beta globina.

Instrucciones:

- Dentro de `data` crea un archivo llamado `hbb.faa` que contenga la hemoglobina beta humana en formato fasta (aquí esta la secuencia):

```
>gi|4504349|ref|NP_000509.1| beta globin [Homo sapiens]
MVHLTPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPKVKAHGKKVLG
AFSDGLAHLDDLKGTFAFLSEKLGCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVAN
ALAHKYH
```

- Genera la línea de instrucción de BLAST desde la línea de comandos para realizar una búsqueda en la base de datos no redundante (nr) de manera remota:

Parámetros requeridos: * Nombre del programa. Seleccionar el blast adecuado. * `-query` indica el archivo de entrada (`hbb.faa` que esta dentro de `data`) * `-remote` indica que la base de datos a utilizar va a buscarla en los servidores de NCBI (si no usamos este argumento buscará la base de datos en el directorio donde está la query) * `-db nr` : indica la base de datos (nr en nuestro caso) * El archivo de salida debe llamarse `hbb.faa.nr.f7` y debe guardarse en la carpeta `results` . * Usar el formato de salida 7.

Nota: Si quieres ejecutar el blast para probar si tu instrucción esta correcta tardará un poco. Puedes correrlo en background para liberar tu terminal y seguir con el examen. (Si tienes error en tu instrucción y no puedes solucionarlo, copia el resultado del blast disponible en `/home/compu2/WelcomeBioinfo/datos/examen-final` para que continúes con las preguntas). El máximo número de resultados por default es de 500.

Análisis de los resultados del blast [60%]

En esta sección vas a realizar algunos filtros sobre el resultado del blast. Debes estar posicionado en la carpeta `examen-final` , desde ahí deberás realizar todos los comandos.

¿Qué vamos a evaluar?:

- Uso de rutas relativas
- nombrado correcto de archivos
- comandos correctos, es decir que funcionan.

Análisis de los datos

- Explica brevemente los siguientes conceptos
 - a. *Alineamiento global* :
 - b. *Alineamiento local* :
 - c. *% de similitud* :
 - d. *% de identidad* :
 - e. *gap* :
 - f. ¿qué se toma en cuenta para decidir que una secuencia es homóloga a otra?
- ¿Cuál es el total de alineamientos encontrados ?
- Manda a un archivo todos los identificadores únicos de las proteínas con los que hizo match la secuencia query.
- ¿Cuántos alineamientos toman en cuenta el tamaño completo de la secuencia query?
- ¿Cuántas secuencias alineadas tienen el mismo tamaño que la secuencia query?
- ¿Cuántas secuencias alineadas son del mismo tamaño que la secuencia query y son 100% idénticas?
- ¿Cuál es el total de secuencias alineadas con menos de 10 gaps?