

Análisis de secuencias genómicas con `sed`

Objetivo del caso

Explorar el comando `sed` para procesar y analizar archivos de secuencia en formato FASTA. Los alumnos aprenderán a hacer sustituciones, eliminar líneas, trabajar con rangos y usar patrones para modificar archivos de manera eficiente.

- **Cognitivo:** Comprender el funcionamiento de `sed` y reconocer cuándo y cómo utilizarlo en el procesamiento de archivos de texto genómico.
- **Procedimental:** Usar comandos `sed` para editar, limpiar y transformar archivos FASTA mediante sustituciones, eliminaciones y rangos de líneas.
- **Actitudinal:** Desarrollar autonomía y criterio para elegir herramientas adecuadas que mejoren la eficiencia y reproducibilidad en análisis bioinformáticos.

Archivos a usar

`secuencias.fasta`

```
>gene1
ATGCGTAGGGTTA
>gene2
atgccctagaaatg
>gene3
ATGCGNNTAGCAT
>gene4
ATGCATGCATGC
>gene5
ATGCTA
>gene6
TTATTG
```

Este archivo contiene 4 secuencias genómicas, algunas en minúsculas, otras con bases ambiguas (como `N`).

🧠 ¿Qué es `sed` ?

`sed` es un **editor de flujo de texto**. Permite **buscar, reemplazar, eliminar o modificar** texto, línea por línea, usando expresiones regulares y comandos compactos. Es ideal para automatizar cambios en archivos de texto.

🔧 Sintaxis básica

```
sed 'comando' archivo
```

- `'comando'` : operación a realizar (como `s/patrón/reemplazo/`)
- `archivo` : archivo de texto de entrada

Opciones y comandos comunes de `sed`

Opción / Comando	Qué hace
<code>s/pat/reemp/</code>	Sustituye el patrón por el reemplazo (solo la primera coincidencia)
<code>s/pat/reemp/g</code>	Sustituye todas las coincidencias en la línea
<code>d</code>	Elimina la línea que coincide con el patrón
<code>p</code>	Imprime la línea (usado con <code>-n</code>)
<code>-n</code>	Suprime la salida normal (se usa con <code>p</code>)
<code>#, #</code>	Aplica una operación a un rango de líneas por número
<code>/pat/, /pat/</code>	Aplica una operación entre dos patrones
<code>!</code>	Niega una operación (actúa sobre las líneas que no coinciden)
<code>-e</code>	Permite usar varios comandos <code>sed</code> en una misma instrucción

Ejemplos

Simulando un cat

```
sed '' ecuencias.fasta
```

A veces queremos imprimir **solo las líneas que coincidan** con un patrón. Para eso usamos:

```
sed -n '/patrón/p' archivo
```

- `-n` → desactiva la impresión automática de `sed`.
- `p` → imprime **solo** las líneas que coincidan con el patrón.

```
sed '/^>/p' secuencias.fasta # que pasa?
```

```
sed -n '/^>/p' secuencias.fasta
```

👉 Muestra solo los encabezados (líneas que empiezan con `>`).

////////////////////////////////////

preguntas a responder

Preguntas básicas

1. ¿Cómo ver solo las secuencias (sin encabezados)? Es decir borrar las líneas que empizan con `>`.

```
sed '/^>/d' secuencias.fasta
```

- `^>` indica líneas que comienzan con `>`.
- `d` elimina esas líneas.  Esto deja solo las secuencias (sin los nombres de los genes).

2. ¿Cómo reemplazar una base (por ejemplo, `G` por `g`) en todo el archivo?

```
sed 's/G/g/g' secuencias.fasta
```

- `s/` → sustituir
- `G` → buscar letra
- `g` → reemplazo
- `/g` al final → global (todas las apariciones en la línea)

3. ¿Cómo cambiar la primera `A` de cada línea por `*`?

```
sed 's/A/*/ ' secuencias.fasta
```

- Solo afecta la primera **A** por línea.

4. ¿Cómo reemplazar **ATG** por **xxx** , solo una vez por línea?

```
sed 's/ATG/xxx/' secuencias.fasta
```

- **s/ATG/xxx/** reemplaza la primera coincidencia de **ATG** .

◆ Preguntas intermedias

1. ¿Cómo convertir todas las secuencias a mayúsculas?

```
tr 'a-z' 'A-Z' < secuencias.fasta
```

- **tr** convierte caracteres uno por uno.
- Este paso no lo hace **sed** , pero es útil para preprocesamiento.

2. ¿Cómo eliminar las líneas que contienen letras ambiguas (como **N**)?

```
sed '/N/d' secuencias.fasta
```

- Busca líneas con **N** y las elimina.
- No discrimina si es encabezado o secuencia.

3. ¿Cómo modificar solo una línea específica del archivo?

```
sed '6s/N/-/g' secuencias.fasta
```

- En la línea 6, reemplaza **N** por **-** .

4. ¿Cómo cambiar una base solo en un rango de líneas?

```
sed '2,4s/A/a/g' secuencias.fasta
```

- De la línea 2 a la 4 (rango), reemplaza todas las **A** por **a** .

5. Pero si quiero reemplazar 2 líneas, no un rango? por ejemplo reemplazar las **A** por **a** de la línea 2 y la 4 (no rango).

```
sed -e '2s/A/a/g' -e '4s/A/a/g' secuencias.fasta
```

- `-e` permite ejecutar varios comandos de sed.

o bien

```
sed '2s/A/a/g; 4s/A/a/g' secuencias.fasta
```

Usa punto y coma `;` para separar instrucciones.

◆ Preguntas avanzadas

1. ¿Cómo sustituir una base específica en un gen determinado usando patrones?

```
sed '/>gene2/, />gene3/{s/T/U/g}' secuencias.fasta
```

- Del encabezado `>gene2` hasta el siguiente `>gene3`, cambia `T` por `U`.

✓ Regla práctica

Siempre que uses un **rango** y una acción, pon la acción dentro de `{ }`.

2. ¿Cómo modificar todas las secuencias excepto una en particular?

```
sed '/>gene4/, />gene5!s/T/U/g' secuencias.fasta
```

- `!` aplica la sustitución a todo **menos** ese rango.

Como funciona `!`

```
<rango o patrón>!comando
```

- `2,4!d` → elimina **todas las líneas excepto** de la 2 a la 4.
- `/^>/!d` → elimina todo **excepto** las líneas que **empiezan con** `>`.

El `!` se coloca inmediatamente después del rango o patrón, y antes del comando.

🎯 Actividades para los alumnos

1. Cambia todas las apariciones de `G` por `g` solo en las secuencias (no en los encabezados).

- 💡 Pista: evita líneas que empiecen con `>`.
2. Reemplaza `TAG` por `***` solo si está dentro de `gene3`.
 - 💡 Busca `>gene3`, aplica cambio hasta `>gene4`.
 3. Cambia todas las letras minúsculas por mayúsculas en todo el archivo.
 4. Reemplaza todas las `T` por `U`, excepto en `gene4`.
 - 💡 Puedes usar `!` con un rango o hacer dos pasos con `sed`.
- ////////////////////////////////////



Conclusiones

Este caso enseña a usar `sed` paso a paso, desde operaciones básicas hasta manipulaciones complejas de archivos FASTA. A medida que los alumnos entienden cómo combinar patrones, rangos y sustituciones, ganan herramientas muy poderosas para automatizar procesos en bioinformática.